Compétence	Critère d'évaluation	
A1. Programmer la collecte de données	C1. Automatiser l'extraction de données depuis un service web	
	- Identification des contraintes techniques propres aux sources de données	☐
	- Rédaction des spécifications techniques pour l'extraction des données.	☐
	- Construction les requêtes HTTP pour la récupération des données depuis un service web (REST*).	☐
	- Lecture d'un fichier de données dans un script	☐
	- Téléchargement de l'HTML d'une ou plusieurs pages web visées par une action de scraping.	☐
	- Connexion programmatique à un système de gestion de base de données et à un système big data	☐
	- Programmation des filtrages/parsing des données utiles dans les résultats obtenus depuis : une API, depuis la lecture d'un ou de plusieurs fichiers de données, et depuis l'HTML collecté d'un site web	☐
	- Exécution programmatique des requêtes d'extraction de type SQL*.	☐
	- Exécution programmatique des requêtes d'extraction depuis un système big data.	☐

C2. Développer des requêtes de type SQL d'extraction des données depuis un système de gestion de base de données et un système big data en appliquant le langage de requête propre au système afin de préparer la collecte des données nécessaires au projet.	
- Ecriture des requêtes d'extraction de type SQL de récupération de données stockées en base de données et depuis un système big data (Hive	☐
- Documentation des requêtes d'extraction	☐
C3. Développer des règles d'agrégation de données issues de différentes sources en programmant, sous forme de script, la suppression des entrées corrompues et en programmant l'homogénéisation des formats des données afin de préparer le stockage du jeu de données final	
- Rédaction des spécifications techniques pour l'agrégation des données.	☐
- Programmation des règles d'agrégation des données collectées depuis chaque source en un jeu de données brutes unique.	☐
- Programmation de l'identification des entrées corrompues dans le jeu de données (par exemple, données partielles et/ou manquantes)	☐
- Programmation de la suppression des entrées corrompues.	☐
- Programmation de l'identification des entrées au format non normalisé.	☐
- Programmation de la l'homogénéisation des formats de données (par exemple, format des dates, des unités, etc.)	☐
- Versionnement* des scripts avec Git et un dépôt Git en ligne.	☐
- Documentation des scripts.	☐

A2. Développer la mise à disposition technique des données collectées pour un projet d' intelligence artificielle	C4. Créer une base de données dans le respect du RGPD en élaborant les modèles conceptuels et physiques des données à partir des données préparées et en programmant leur import afin de stocker le jeu de données du projet.	
	- Rédaction des spécifications techniques pour le stockage des données.	☐
	- Modélisation de la structure des données de la base de données selon la méthode Merise*.	☐
	- Choix du système de gestion de base de données.	☐
	- Création de la base de données dans le système de gestion de base de données.	☐
	- Documentation de la procédure d'installation du système de gestion de base de données.	☐
	- Rédaction ou mise à jour du registre des traitements de données personnelles en vue de la mise en conformité de la base de données avec le RGPD.	☐
	- Rédaction des procédures de tri des données personnelles stockées dans la base de données pour la mise en conformité avec le RGPD (par exemple : détection et suppression des données personnelles	☐
	- Programmation du script d'import des données en base de données.	☐
	- Documentation du script d'import	☐

	C5. Développer une API mettant à disposition le jeu de données en utilisant l'architecture REST afin de permettre l'exploitation du jeu de données par les autres composants du projet	
	- Rédaction des spécifications techniques des moyens de mise à disposition et d'accès aux données du projet : API (REST) et accès direct à la base de données.	☐
	- Configuration des accès au jeu de données depuis le serveur de l'API.	☐
	- Développement de la réception et de la validation des requêtes client	☐
	- Développement des requêtes à la base de données en fonction de la mise à disposition des données prévues par les spécifications.	☐
	- Développement des réponses de l'API au client.	☐
	- Développement des règles d'autorisation et d'accès aux points de terminaison de l'API REST.	☐
	- Sécurisation de l'API : Top 10 OWASP API1 par exemple.	☐
	- Rédaction de la documentation technique de l'API REST.	☐
	- Rédaction de la documentation technique d'accès à la base de données adaptée aux environnements techniques du projet.	☐